

PORTFOLIO

<김기환 / >

Frontend Engineer

HCI와 Visual Analytics 연구에서 시작해 AI 시스템, 제품 플랫폼, 내부 운영 자동화로 이어진 작업을 정리했습니다. 복잡한 시스템을 사람이 이해하고 사용할 수 있게 만든 프론트엔드 구현과 브라우저 자동화 작업입니다.

01 Internal Operations Automation

내부 도구와 외부 서비스 조회를 연결한 브라우저 자동화

02 RiGrid 서버 주도 UI

운영 UI 변경과 A/B 테스트를 배포 일정과 분리한 구조

03 Rendering Performance

대용량 콘텐츠 환경을 위한 가상화와 렌더링 최적화

04 AutoML · 예측 설명 UI

비전문가도 AI 예측 근거를 검증할 수 있는 UI

05 Transparent Exploration in Recommender Systems

추천 설명이 사용자 피드백에 미치는 영향을 검증한 실험 시스템

PageAgent 기반 내부 운영 자동화

Generative UI를 단순히 화면을 생성하는 기술이 아니라, 여러 내부 시스템을 연결하고 조작하는 Agent 실행 레이어로 재정의한 작업입니다.

PageAgent

Generative UI

Browser Automation

QA/CS Automation

Internal Operations

Problem

예를 들어 카카오 계정으로 구매한 사용자가 네이버 계정으로 로그인해 구매 내역이 보이지 않는 CS가 들어오면, 운영자는 여러 도구를 오가며 구매 귀속 계정을 추적해야 했습니다.

- 소셜 로그인 계정 간 구매 귀속 확인
- 유저, 결제, 계정 매핑 테이블의 순차 조회
- 배송 이슈에서는 택배사 외부 서비스까지 조회
- 운영자가 매번 조회 순서를 직접 판단해야 하는 부담

Initial Hypothesis

요청마다 확인해야 할 정보와 순서가 달라지기 때문에, 자연어 요청에 맞춰 조회 흐름과 UI를 동적으로 구성하면 탐색 업무를 줄일 수 있을 것이라 기대했습니다.

- 정적인 어드민 화면을 추가하는 대신 동적 조사 흐름 구성
- 계정 후보, 결제 내역, 매핑 결과를 한 화면에서 재구성
- 운영자가 다음에 볼 테이블과 순서를 직접 판단하는 부담 감소

Why Generative UI Was Not Enough

실제로는 UI를 새로 만드는 것보다 기존 사내 도구를 오가며 정확하게 조회하고 조작하는 능력이 더 중요했습니다.

정보가 여러 어드민과 탭에 분산

조회와 입력은 여전히 사람이 수행

핵심은 서비스 이동과 조작

Key Insight

내부 도구에서 중요한 것은 UI 생성이 아니라, 여러 시스템을 연결하고 조작하는 능력이다.

Approach

PageAgent를 기반으로 사용자의 자연어 요청을 실행 가능한 action sequence로 변환하고, 브라우저에서 실제 UI를 조작한 뒤 결과를 다시 운영자가 이해하기 쉬운 형태로 재구성했습니다. 익스텐션 기반 구조를 통해 탭마다 분리된 브라우저 컨텍스트의 데이터를 Agent 레이어에서 이어 붙일 수 있었습니다.

Natural Language
운영자 요청**LLM**
의도 해석**PageAgent**
UI 조작 실행**Browser**
여러 탭 이동**Result UI**
정보 재구성

Example Scenario

위와 같은 CS 조사 업무에서, Agent 적용 전후의 작업 흐름은 다음처럼 달라집니다.

Before

- 1. 문의 정보에서 후보 사용자 식별
- 2. 유저 어드민에서 소셜 계정 확인
- 3. 계정 매핑 테이블에서 동일 사용자 후보 탐색
- 4. 결제 어드민에서 구매 귀속 계정 조회
- 5. 필요 시 택배사 등 외부 서비스까지 조회
- 6. 여러 탭의 결과를 사람이 직접 종합

After

- 1. 운영자가 자연어로 조사 요청
- 2. Agent가 필요한 조회 순서 생성
- 3. PageAgent가 여러 탭에서 click/input 수행
- 4. 구매 귀속 계정과 현재 로그인 계정의 차이 요약
- 5. CS 답변에 필요한 결과 UI 제공

Architecture

- **LLM:** 사용자 명령을 해석하고 실행 가능한 작업 흐름 생성
- **PageAgent:** 브라우저 탭 이동, 버튼 클릭, 입력 등 실제 UI를 조작하고, 탭 간 분리된 데이터를 Agent 레이어에서 연결
- **Chrome Managed Profile:** 사내 도구 접근 권한과 인증 세션을 유지하고, 브라우저 익스텐션 형태로 Agent를 배포하는 채널
- **UI Layer:** 수집한 정보를 운영자가 판단하기 쉬운 결과로 재구성

Implementation Scope

PageAgent의 브라우저 조작 엔진을 새로 만든 것이 아니라, 내부 운영 도구에 맞는 통합 레이어와 업무 실행 흐름을 설계하고 검증했습니다.

- **Workflow Mapping:** CS/QA 요청을 PageAgent가 수행 가능한 action sequence로 변환하는 업무 흐름 정의
- **Selector Strategy:** 반복 사용 UI는 전용 selector로 연결해 시각 탐색 의존도를 낮추고 조작 안정성 강화
- **Extension Context:** 탭마다 분리된 브라우저 컨텍스트를 운영 업무 단위로 이어 붙이는 구조 검토
- **Result Contract:** 수집 근거와 요약 결과를 분리해 운영자가 검증 가능한 형태로 재구성

Impact

반복 조사 단순화

내부 어드민과 외부 서비스를 오가던 QA/CS 흐름을 자동화 대상으로 정리

기존 UI 유지

기존 어드민 위에 실행 레이어를 추가하는 방향 검증

재현성 강화

전용 selector로 시각 탐색 비용 축소

What I Learned

- Generative UI는 standalone으로는 내부 운영 도구의 문제를 해결하기 어렵다.
- Agent와 결합했을 때 실제 업무 자동화 가치가 커진다.
- 내부 도구에서는 정확성, 재현성, 감사 가능한 실행 흐름이 핵심이다.
- UI를 새로 만드는 것보다 기존 시스템을 안정적으로 연결하고 조작하는 능력이 더 중요하다.

RiGrid 기반 Server Driven UI

콘텐츠 플랫폼의 UI 구성과 비즈니스 데이터를 분리하고, Grid/Cell 단위로 재사용 가능한 클라이언트 렌더링 구조를 설계한 작업입니다.

Server Driven UI

RiGrid

GraphQL

Multi-platform UI

Problem

기존 콘텐츠 UI는 비즈니스 데이터와 표시 로직이 강하게 결합되어, 레이아웃이나 섹션 구성이 바뀔 때마다 여러 클라이언트 코드 수정이 필요했습니다.

- 플랫폼별로 유사한 UI 로직이 중복 구현됨
- 운영 실험이나 콘텐츠 구성을 바꾸기 위해 앱/웹 배포가 필요함
- 작품 상세, 랜딩, 검색처럼 서로 다른 화면에서 재사용 가능한 구조가 부족함

Approach

서버가 Grid와 Cell 구조를 내려주고, 클라이언트는 schema에 맞춰 Cell tree를 재구성한 뒤 대응되는 컴포넌트를 렌더링하는 구조로 접근했습니다.

- GraphQL schema 기반 Grid/Cell 인터페이스 정의
- Cell의 layout과 type으로 UI 표현과 데이터 바인딩을 분리
- AsyncCell, ChildCells, FlexColumnCell 등 유틸리티 Cell로 조합성 보강

Implementation Focus

Client Renderer

서버 응답의 Cell 목록을 트리로 재구성하고, layout/type에 맞는 컴포넌트로 매핑

Compatibility

기존 클라이언트가 깨지지 않도록 추가 중심의 schema 변경과 점진적 전환 고려

Operational Flexibility

Cell 단위 조합으로 랜딩/검색/상세 화면의 콘텐츠 구성과 실험 가능성 확대

Impact

- UI 데이터와 비즈니스 데이터를 분리해 변경 영향 범위를 줄이는 방향 검증
- 기획, 디자인, 개발이 Cell 단위 구조를 공유하며 협업할 수 있는 공통 언어 확보
- 마케팅 랜딩 페이지와 검색 페이지 등 다양한 화면으로 Server Driven UI 적용 범위 확장
- 부분 전환 과정에서 middleware 병목과 성능 저하를 확인하고, 전체 전환 필요성을 정리

대규모 콘텐츠 렌더링 최적화

예상보다 큰 콘텐츠 목록을 안정적으로 렌더링하기 위해 DOM 수, 네트워크 페이로드, 사용자 상호작용 지연을 함께 줄인 프론트엔드 성능 개선 작업입니다.

Virtualization

React

Performance

Large Lists

Problem

250개 작품 기준으로 만들어진 페이지가 실제 이벤트에서 6,000개 이상의 작품을 다루게 되면서 렌더링과 상호작용 성능이 급격히 나빠졌습니다.

- 대량 DOM 렌더링으로 저사양 기기에서 초기 표시가 지연됨
- 스켈레톤과 실제 아이템 렌더링 책임이 한 컴포넌트에 섞임
- 필터 변경 시 네트워크 재요청과 메인 스레드 부하가 함께 발생함

Approach

화면에 보이는 아이템만 렌더링하도록 리스트 가상화를 적용하고, skeleton 표현과 데이터 필터링 흐름을 분리해 체감 성능을 개선했습니다.

- window scroll과 결합한 list virtualization 적용
- SVG background 기반 skeleton으로 렌더링 책임 분리
- gzip 압축과 클라이언트 필터링 구조 검토

Implementation Focus

Rendering Budget

전체 DOM을 한 번에 그리지 않고 viewport 주변 아이템만 유지하도록 구조 변경

Skeleton Strategy

스켈레톤을 반복 background로 처리해 가상화 컴포넌트의 관심사를 단순화

Interaction Cost

필터링 중 perceived loading과 실제 데이터 처리 비용을 함께 분석하고 개선

Impact

- 대량 콘텐츠 목록에서도 초기 렌더링과 스크롤 체감 성능을 유지할 수 있는 구조 확보
- 스켈레톤 표시와 실제 아이템 렌더링을 분리해 컴포넌트 책임을 명확하게 정리
- 큰 JSON payload에 gzip을 적용해 전송 크기를 약 1/8 수준까지 줄일 수 있음을 확인
- 필터링 로직에서 네트워크 비용과 CPU 비용을 함께 봐야 한다는 기준을 정립

Enterprise AutoML XAI 기능 개발

정형 데이터 기반 AutoML 모델을 기업 의사결정에 활용할 수 있도록, 모델 단위와 개별 예측 단위의 설명 기능을 설계하고 구현한 작업입니다.

AutoML

Explainable AI

Tabular Data

Decision Tree

What-if UX

Problem

ERP, HR, CRM처럼 정형 데이터가 이미 축적된 영역에서는 AutoML 적용 가능성이 높았지만, 기업 사용자가 예측값만 보고 의사결정에 반영하기는 어려웠습니다.

- 정확도가 높아도 왜 그런 예측이 나왔는지 설명할 수 있어야 함
- 인사평가, 채용, 수요 예측처럼 설명 책임이 필요한 업무가 존재
- ML 비전문가가 모델을 검증하고 배포 여부를 판단할 수 있는 UX가 필요

Approach

전체 모델의 주요 변수는 Feature Importance로 설명하고, 개별 예측은 Local Surrogate Model과 대표 인스턴스를 통해 설명하는 구조로 접근했습니다.

- Decision Tree/Ensemble 모델의 해석 가능성과 사용성 한계 분석
- 클러스터링 기반 prototype sampling으로 대표 데이터 인스턴스 추출
- 사용자가 입력값을 바꾸며 예측 변화와 근거를 확인하는 What-if 흐름 구성

Implementation Focus

Global Explanation

Feature Importance 기반으로 모델 전체에서 중요한 변수를 정렬하고 시각화

Local Explanation

개별 예측을 설명하기 위해 surrogate model과 feature contribution을 제공

Validation UX

대표 인스턴스와 직접 입력한 행 데이터로 edge case를 검증하는 인터페이스 구성

Impact

- AutoML을 단순 예측 자동화 도구가 아니라 배포 전 검증 가능한 제품 흐름으로 확장
- ML 비전문가도 모델의 주요 판단 근거와 개별 예측의 이유를 확인할 수 있게 개선
- ERP/HR/CRM 등 기업 정형 데이터 기반 AI 기능의 적용 가능성과 검증 기준을 정리
- 예측값, 규칙 경로, 변수 기여도를 함께 보여주는 XAI 시각화 UI를 제품화

추천 시스템 탐색 UI 실험 플랫폼

추천 시스템의 Explore-Exploit 문제에서 탐색 아이템을 어떻게 설명해야 사용자 경험과 피드백 품질을 함께 개선할 수 있는지 검증한 연구/구현 작업입니다.

Recommender Systems

Experiment Platform

User Study

Flask

Python

Problem

추천 시스템은 사용자의 취향을 더 잘 파악하기 위해 때때로 취향과 맞지 않을 수 있는 탐색 아이템을 노출해야 하지만, 사용자는 이를 낮은 품질의 추천으로 인식할 수 있습니다.

- 탐색 아이템 노출이 사용자 신뢰와 피드백 품질에 미치는 영향이 불명확
- 추천 품질 개선을 위해서는 클릭/평점 로그의 학습 가치까지 함께 평가해야 함
- 실사용에 가까운 환경에서 UI 설명 방식과 사용자 행동을 함께 측정할 필요

Approach

넷플릭스와 유사한 웹 기반 영화 추천 실험 시스템을 구현하고, 탐색 아이템 노출의 투명성이 사용자 행동과 로그 가치에 미치는 영향을 측정했습니다.

- 영화 추천 목록, 상세 정보, 피드백 수집을 포함한 실험 UI 구현
- Amazon MTurk에서 94명의 피험자를 모집해 실사용 로그와 설문 응답 수집
- 추천 모델 학습 관점에서 사용자 로그의 가치를 평가하는 metric 제안

Implementation Focus

Experiment Platform

웹 기반 영화 추천 시스템을 구현해 추천 목록, 탐색 아이템, 피드백 흐름 제공

Transparent UX

사용자에게 낯선 추천이 왜 노출되는지 설명하는 UI 조건을 설계하고 비교

Data Quality Metric

수집된 로그가 추천 모델 개선에 얼마나 기여하는지 평가하는 지표 제안

Impact

- 추천 품질 문제를 알고리즘 성능뿐 아니라 사용자가 어떤 맥락에서 피드백을 남기는가의 문제로 확장
- AI 제품에서 모델 개선과 사용자 경험이 서로 연결된다는 점을 실험 시스템으로 검증
- 실사용 로그, 설문 응답, 추천 모델 평가 지표를 함께 다루는 end-to-end 실험 흐름 구축
- 대학원 연구 결과를 제품형 실험 플랫폼과 데이터 기반 UX 설계 사례로 정리